

Press  to exit full screen

ANALYSE DU CATALOGUE NETFLIX AVEC POWER BI

TP D'INTRODUCTION À LA BUSINESS INTELLIGENCE



Money Heist P1:E1 Episode 1



SOMMAIRE

Introduction

Présentation du jeu de données

Définition des indicateurs de performance. 2

- KPI 1 : Nombre de contenus ajoutés par année d'ajout 2
- KPI 2 : Nombre de contenus par type et par pays. 2

Conception du schéma en étoile

- Table de faits
- Dimensions

Table de correspondance source / modèle décisionnel

Implémentation dans Power BI

Réalisation du tableau de bord

- Page 1 - Vue d'ensemble
- Page 2 - Drill-through

Difficultés rencontrées et solutions apportées

Amélioration de l'aspect visuel du dashboard

Conclusion

1. Introduction

Dans le cadre du TP d'introduction à la Business Intelligence, l'objectif était de concevoir un premier tableau de bord Power BI à partir d'un jeu de données. Le travail demandé consistait à identifier deux indicateurs de performance, concevoir un schéma en étoile intégrant une dimension temporelle et au moins deux autres dimensions, établir une table de correspondance entre la source et le modèle décisionnel, implémenter ce schéma dans Power BI, puis concevoir un tableau de bord comportant au minimum un filtre fonctionnel et une page drill-through.

Pour répondre à cette demande, nous avons choisi de travailler sur un jeu de données public issu de Kaggle, intitulé « Netflix Movies and TV Shows », contenant des informations sur les contenus présents dans le catalogue Netflix. Ce choix nous a semblé pertinent car le dataset comporte une dimension temporelle exploitable ainsi que plusieurs axes d'analyse adaptés à une démarche BI, comme le type de contenu, le pays, l'année de sortie ou encore la catégorie.

Ce compte rendu présente les différentes étapes du travail réalisé : l'analyse du jeu de données, la définition des indicateurs, la modélisation du schéma en étoile, la préparation des données, l'implémentation dans Power BI, la réalisation du tableau de bord, ainsi que les principales difficultés rencontrées.



2. Présentation du jeu de données

Le jeu de données retenu est un fichier CSV nommé `netflix_titles.csv`. Il recense les contenus proposés sur Netflix.

Dans une logique décisionnelle, le premier travail a consisté à identifier le grain de la donnée. Ici, chaque ligne du fichier correspond à un contenu Netflix, identifié par un `show_id`. La granularité retenue pour le modèle est donc la suivante :

un fait correspond à un contenu du catalogue.

La structure de la dataset est intéressante car elle permet d'observer la présence d'un contenu dans le catalogue selon plusieurs dimensions d'analyse.

Cependant, le **dataset présentait** néanmoins **quelques limites**. Certaines colonnes contenaient des valeurs manquantes, notamment `country`, `date_added` et `rating`. D'autres colonnes contenaient plusieurs valeurs dans une même cellule, comme `country` ou `listed_in`. Ces caractéristiques rendaient nécessaire une phase de nettoyage et de simplification avant l'implémentation dans Power BI.

3. Définition des indicateurs de performance

KPI 1 : Nombre de contenus ajoutés par année d'ajout

Cet indicateur permet d'analyser l'évolution du catalogue Netflix dans le temps. Il repose sur le champ `date_added`, transformé en véritable date, puis agrégé par année. L'objectif est d'observer les variations du volume de contenus ajoutés au fil du temps.

KPI 2 : Nombre de contenus par type et par pays

Cet indicateur permet d'étudier la structure du catalogue selon deux axes : la nature du contenu (Movie ou TV Show) et son origine géographique (`country`).

Dans les deux cas, la mesure utilisée est le nombre de contenus. Afin de faciliter les calculs dans Power BI, nous avons créé une mesure **`nb_contenu = 1`** pour chaque ligne de la table de faits. Les indicateurs sont ensuite obtenus par agrégation de cette mesure.

4. Conception du schéma en étoile

Nous avons conçu un schéma en étoile centré sur une table de faits unique car l'ensemble des indicateurs reposent sur la même mesure et peut être analysé selon les mêmes dimensions principales.


Table de faits

Dans la table **Fait_Contentu**, chaque ligne correspond à un contenu Netflix et contient :

- show_id
- title
- date_added_clean
- type
- country_clean
- release_year
- rating_clean
- genre_clean
- nb_contenu

Dimensions

- **Dim_Temps** : construite à partir de date_added, avec les attributs date_added_clean, annee_ajout, mois_num, mois_nom et trimestre.
- **Dim_Type** : construite à partir du champ type, permettant de distinguer les films et les séries.
- **Dim_Pays** : construite à partir du champ country, après nettoyage du premier pays indiqué.



5. Table de correspondance source / modèle décisionnel

Les principales règles de transformation :

- **date_added** a été converti en date via une colonne date_added_clean, puis décomposé en année, mois et trimestre
- **country** a été simplifié en ne conservant que le premier pays mentionné dans la cellule et le remplacement des valeurs manquantes par “Unknown”
- **listed_in** a été simplifié selon la même logique, c’est à dire en conservant le premier genre.
- **rating** a été nettoyé en remplaçant les valeurs vides par “Unknown”
- une colonne **nb_contenu = 1** a été ajoutée pour servir de mesure de base

Alimentation de Dim_Temps

Source	Colonne source	Type source	Cible	Colonne cible	Type cible	Transformation
netflix_titles.csv	date_added	texte	Dim_Temps	date_id	entier	clé générée
netflix_titles.csv	date_added	texte	Dim_Temps	date_added	date	conversion texte → date
netflix_titles.csv	date_added	texte	Dim_Temps	jour	entier	extraction du jour
netflix_titles.csv	date_added	texte	Dim_Temps	mois_num	entier	extraction du mois
netflix_titles.csv	date_added	texte	Dim_Temps	mois_nom	texte	dérivation du nom du mois
netflix_titles.csv	date_added	texte	Dim_Temps	trimestre	entier	calcul du trimestre
netflix_titles.csv	date_added	texte	Dim_Temps	annee	entier	extraction de l'année

Alimentation de Dim_Type

Source	Colonne source	Type source	Cible	Colonne cible	Type cible	Transformation
netflix_titles.csv	type	texte	Dim_Type	type_id	entier	clé technique générée
netflix_titles.csv	type	texte	Dim_Type	type_libelle	texte	conservation des valeurs distinctes

Alimentation de Dim_Pays

Source	Colonne source	Type source	Cible	Colonne cible	Type cible	Transformation
netflix_titles.csv	country	texte	Dim_Pays	country_id	entier	clé technique générée
netflix_titles.csv	country	texte	Dim_Pays	country_name	texte	garder le premier pays, trim,

Alimentation de Fait_Contentu

Source	Colonne source	Type source	Cible	Colonne cible	Type cible	Transformation
netflix_titles.csv	show_id	texte	Fait_Contentu	show_id	texte	conservation identifiant source
netflix_titles.csv	date_added	texte	Fait_Contentu	date_id	entier	jointure avec Dim_Temps
netflix_titles.csv	type	texte	Fait_Contentu	type_id	entier	jointure avec Dim_Type
netflix_titles.csv	country	texte	Fait_Contentu	country_id	entier	jointure avec Dim_Pays après règle
netflix_titles.csv	rating	texte	Fait_Contentu	rating_id	entier	jointure avec Dim_Rating
netflix_titles.csv	listed_in	texte	Fait_Contentu	genre_id	entier	jointure avec Dim_Genre
netflix_titles.csv	release_year	entier	Fait_Contentu	release_year_id	entier	jointure avec Dim_Release_Year
calcul ETL	constante	entier	Fait_Contentu	nb_contenu	entier	valeur fixe 1

6. Implémentation dans Power BI

L'implémentation du schéma en étoile a été réalisée **dans Power BI en ligne**. Le fichier CSV a d'abord été importé dans une table source nommée `netflix_titles`. Nous avions initialement prévu d'utiliser Power Query pour préparer les données, ce qui aurait été cohérent avec la démarche ETL vue en cours. Cependant, dans la version web de Power BI, nous avons rencontré un blocage lié à l'accès au fichier source via la passerelle de données. Power Query tentait de lire le fichier via un chemin local ou réseau, inaccessible depuis le service web, ce qui empêchait l'exécution correcte de la requête.


Face à cette difficulté, car nous avons toutes les deux un mac, nous avons choisi une autre méthode à l'aide de **colonnes calculées DAX**, de **tables calculées** et de **relations manuelles**. Cette solution nous a permis d'aboutir malgré les limitations de l'environnement web.

Nous avons créées les colonnes calculées dans `netflix_titles` :

- `country_clean`
- `genre_clean`
- `rating_clean`
- `date_added_clean`
- `annee_ajout`
- `mois_num`
- `mois_nom`
- `trimestre`
- `nb_contenu`

À partir de cette table préparée, nous avons ensuite créé :

- `Dim_Temps`
- `Dim_Type`
- `Dim_Pays`
- `Fait_Contenu`



Les relations ont ensuite été définies manuellement entre la table de faits et les dimensions :


Gérer les relations

+ Nouvelle relation Détection automatique Modifier Supprimer Filtre

De : table (colonne) ↑	Relation	À : table (colonne)	État
☐ Fait_Contentu (country_clean)	* ← 1	Dim_Pays (country_clean)	Actif ...
☐ Fait_Contentu (date_added_clean)	* ← 1	Dim_Temps (date_added_clean)	Actif ...
☐ Fait_Contentu (type)	* ← 1	Dim_Type (type)	Actif ...

Enfin, la mesure principale suivante a été créée :

Nb_Contentus = SUM(Fait_Contentu[nb_contenu])




7. Réalisation du tableau de bord

→ Page 1 — Vue d'ensemble

La page présente :

- un filtre fonctionnel sur le type de contenu
- une carte affichant le nombre total de contenus
- un graphique montrant le nombre de contenus ajoutés par année, limité aux années récentes pour faciliter la lecture (depuis 2015)
- un graphique de répartition des contenus par type
- un graphique affichant le Top 10 des pays les plus représentés dans le catalogue

Cette page permet de visualiser rapidement les deux KPI retenus et de fournir une lecture globale du dataset.





Page 2 — Drill-through


La deuxième page a été conçue comme une page de drill-through par pays.

Depuis le **graphique des pays de la page 1**, un clic droit sur un pays permet d'ouvrir une page de détail filtrée automatiquement sur le pays sélectionné.

Cette page contient :

- un graphique de répartition par type
- un graphique d'évolution par année
- un tableau listant les contenus correspondants avec leur titre, leur genre, leur rating et leur année de sortie.

Ce dispositif permet de passer d'une vision synthétique à une analyse plus détaillée.





8. Amélioration de l'aspect visuel du dashboard

Afin d'aller plus loin, le **dashboard a été retravaillé** sur le plan visuel en s'**inspirant** de dashboards modernes observés sur **Dribbble**. L'objectif était d'améliorer la lisibilité et le rendu global.

Les principales améliorations ont été de rentrer dans l'univers Netflix en passant à un fond sombre, en ajoutant des blocs visuels arrondis pour structurer la page, changer les couleurs avec l'identité Netflix, remplacement du bleu standard par le rouge Netflix, et l'uniformisation des titres avec l'amélioration de la disposition des éléments.

Le résultat du dashboard nous semble plus cohérent, plus agréable à lire et plus professionnel.



9. Difficultés rencontrées

Nous avons rencontrées plusieurs difficultés au cours de la réalisation du TP.

1. La première difficulté a concerné Power Query dans la version web de Power BI. Nous avons donc renoncé à cette approche pour privilégier une préparation des données directement dans le modèle via DAX.
2. La deuxième difficulté a concerné la dimension temps. Lors de la création de la relation entre Dim_Temps et Fait_Contenu, Power BI refusait la cardinalité attendue car la colonne date_added_clean contenait des valeurs vides. Nous avons résolu ce problème en recréant la dimension temps sans les dates nulles, ce qui a permis de définir une relation correcte de type un-à-plusieurs.
3. Nous avons également rencontré plusieurs difficultés de paramétrage des visuels :
 - l'agrégation automatique du champ release_year sous la forme "Somme de release_year", que nous avons corrigée en choisissant l'option "Ne pas résumer"
 - l'apparition de valeurs parasites dans la dimension type, résolue en recréant manuellement Dim_Type avec les deux seules modalités attendues : Movie et TV Show
 - l'ajustement de certains visuels afin de rendre le dashboard plus lisible, notamment la restriction du graphique temporel aux années à partir de 2015 et le filtrage du graphique pays au Top 10.

Ces difficultés ont finalement été utiles car elles nous ont permis de mieux comprendre le fonctionnement de Power BI, la logique des relations dans un schéma en étoile, ainsi que les différences entre préparation des données dans Power Query et dans le modèle.

10. Conclusion

Ce TP nous a permis de mettre en pratique les notions introduites en cours (choix d'indicateurs, définition d'une mesure, modélisation dimensionnelle, construction d'un schéma en étoile, préparation des données, implémentation dans Power BI et conception d'un tableau de bord).

Malgré certaines limites du dataset et des contraintes liées à l'utilisation de Power BI en ligne, nous avons pu construire un modèle cohérent et aboutir à un dashboard conforme. Ce sont ces étapes qui rendent ensuite l'analyse possible et lisible pour un utilisateur final.